Laporan GSLC Deep Learning Sesi 05 - Transfer Learning

Identitas

Data	Isian
Nama	David Christian Golden Mahaviro
NIM	2802501306
Mata kuliah	Deep Learning
Dataset	Oxford-IIIT Pet, 10 kelas (5 kucing, 5 anjing), split 70/15/15
Tautan repositori GitHub	https://github.com/davidhoky/Deep-Learning

Bagian A: Analisis Konseptual

A1. Efek regularisasi Batch Normalization (Slide 6-8)

Batch Normalization memberikan efek regularisasi ringan melalui mekanisme perhitungan statistiknya saat proses *training* (Slide 8). Metode ini menormalisasi fitur menggunakan nilai rata-rata dan varians yang dihitung hanya dari sebagian data saja atau mini-batch (Slide 7). Karena komposisi sampel pada mini-batch terus berubah secara acak, estimasi statistik ini secara alami menghasilkan *noise* pada setiap iterasinya. Fluktuasi ini mencegah model terlalu bergantung pada nilai aktivasi yang persis, sehingga dapat mengurangi *overfitting*, dan membuat penggunaan Dropout sering kali tidak lagi diperlukan (Slide 8).

Namun, asumsi tidak perlunya Dropout ini tidak berlaku dan justru memicu instabilitas pelatihan apabila model menggunakan ukuran mini-batch yang sangat kecil. Pada *batch size* kecil, estimasi rata-rata dan varians menjadi sangat melenceng dan tidak representatif, sehingga merusak arah konvergensi. Selain itu, pada skenario model yang sangat kompleks dan rentan mengalami *overfitting* ekstrem, regularisasi ringan dari Batch Normalization ini tidak cukup kuat, sehingga Dropout masih tetap dibutuhkan pada bagian lapisan pengklasifikasi.

A2. Degradation problem dan formulasi residual (Slide 10-12)

Penambahan lapisan pada arsitektur CNN konvensional sering memicu masalah degradasi karena optimisasi berulang melalui aktivasi non-linear membuat jaringan sangat kesulitan mempelajari fungsi identitas secara murni, sehingga menyebabkan error pelatihan justru memburuk (Slide 10).

Skip connection pada blok residual mengatasi hambatan ini dengan merumuskan output lapisan sebagai y = F(x) + x (Slide 11). Saat proses backpropagation, elemen + x ini menciptakan "jalan pintas" karena gradien terhadap x sama dengan gradien terhadap y dikali (1 + turunan F), sehingga turunan dari fungsi identitas bernilai 1. Hal ini memungkinkan gradien untuk mengalir langsung ke lapisan-lapisan awal tanpa sepenuhnya terdistorsi oleh perkalian turunan fungsi F(x).

Mekanisme jalan pintas ini sangat krusial dalam memitigasi fenomena vanishing gradient. Dengan mengamankan magnitudo gradien agar tidak menyusut drastis saat merambat mundur, jaringan mendalam seperti ResNet dapat mempertahankan arus informasi secara utuh (Slide 10) dan mampu mencapai konvergensi yang stabil meski memiliki arsitektur yang sangat dalam (Slide 12).

A3. Feature extraction vs fine-tuning (Slide 14-16)

Feature Extraction mempertahankan bobot *pretrained backbone* secara statis dan hanya melatih *classifier head* baru, sehingga memperbarui parameter dalam jumlah yang sangat sedikit (Slide 16). Hal ini secara teoritis menghemat beban komputasi serta memori, dan sepenuhnya menghilangkan risiko *destructive gradient updates* pada fitur dasar. Sangat cocok jika jumlah data latih sangat minim atau karakteristik dataset baru mirip dengan *ImageNet* (Slide 15).

Sebaliknya, Fine-Tuning membuka blokade bobot pada seluruh atau sebagian *backbone network* agar ikut diperbarui selama *training* (Slide 16). Model menyesuaikan arsitektur fiturnya secara mendalam agar sesuai dengan domain baru. Konsekuensinya, parameter yang diperbarui melonjak drastis, meningkatkan beban komputasi dan memori per epoch, serta mensyaratkan ketersediaan data yang lebih melimpah untuk mencegah *overfitting*. Fine-Tuning rentan memicu *catastrophic forgetting* jika *learning rate* terlalu tinggi pada lapisan awal (Slide 16, 28). Gunakan Fine-Tuning saat domain data berbeda signifikan dari *ImageNet* dan tersedia dataset yang cukup besar.

A4. Kaidah penerapan data augmentation (Slide 20-22)

Data augmentation bertujuan mensimulasikan variasi data baru agar model belajar generalisasi yang lebih baik dan tidak overfit, sehingga secara metodologis hanya diaktifkan pada train set (Slide 20). Pada validation dan test set, augmentasi harus dinonaktifkan agar metrik evaluasi benar-benar mencerminkan performa asli model terhadap kondisi data natural di dunia nyata tanpa distorsi buatan, sehingga pengukurannya tetap objektif.

Untuk klasifikasi ras hewan peliharaan, teknik transformasi seperti perubahan warna yang ekstrem (Color Jitter pada aspek Hue) sangat tidak layak digunakan (Slide 21). Argumentasinya berlandaskan pada invariansi semantik label: warna bulu sering kali menjadi ciri penentu utama dari sebuah ras. Jika augmentasi secara radikal mengubah warna asli citra hewan, identitas semantik dari label ras tersebut akan rusak dan hilang. Hal ini justru akan membingungkan model karena dipaksa mempelajari representasi visual yang keliru dan tidak merepresentasikan kelas aslinya.

A5. Mitigasi catastrophic forgetting (Slide 28-29)

Catastrophic forgetting adalah fenomena di mana model pra-latih (pretrained) melupakan fitur visual dasar yang telah dipelajarinya dengan baik saat disesuaikan (fine-tuning) pada data baru (Slide 28). Hal ini terjadi karena proses adaptasi yang terlalu agresif, seperti penggunaan learning rate yang besar sejak awal, merusak struktur bobot berharga (misalnya pendeteksi tepi atau warna) yang terbangun selama pre-training. Akibatnya, representasi aslinya hilang dan generalisasi memburuk.

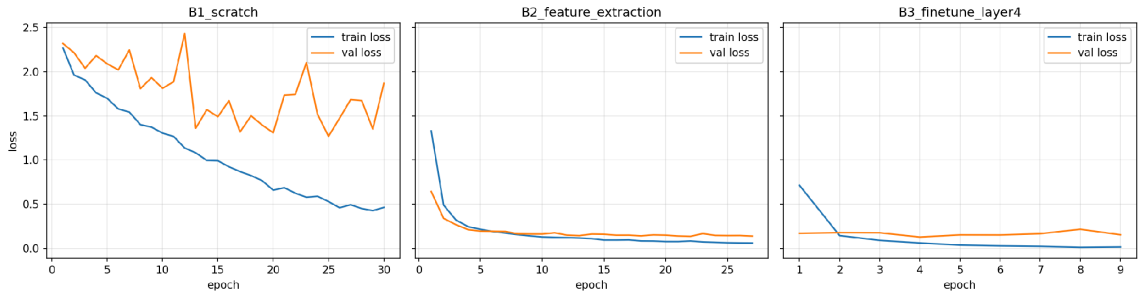
Strategi pertama untuk memitigasi hal ini adalah gradual unfreezing, yaitu membekukan sebagian besar lapisan saat melatih classifier baru, lalu membuka blokade lapisan secara bertahap (Slide 16). Secara teoritis, head baru yang masih acak dilatih dulu agar gradien awalnya tidak merusak backbone, dan lapisan atas yang spesifik dibuka sebelum lapisan awal yang generik. Strategi kedua adalah menggunakan

learning rate scheduler dengan warmup (Slide 29), yang menerapkan laju pembelajaran rendah dan dinaikkan perlahan, sehingga pembaruan bobot awal yang besar dan merusak dapat dicegah, menjaga integritas parameter pretrained yang krusial.

C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Kondisi	Strategi	Trainable params	Learning rate	Epoch konvergen (epoch dijalankan)	Waktu pelatihan (detik)	Val acc	Gap train-val	Test Macro F1
B1	From scratch	11.181.642	all=1e-3	25 (30)	447,9	0,6195	0,2023	0,6055
B2	Feature extraction	5.130	fc=1e-3	22 (27)	375,7	0,9562	0,0200	0,9667
B3	Fine-tuning layer4 + fc	8.398.858	layer4=1e-4; fc=1e-3	4 (9)	121,7	0,9630	0,0197	0,9530
B4	B3 tanpa augmentasi	8.398.858	layer4=1e-4; fc=1e-3	4 (9)	81,4	0,9697	0,0303	0,9563
B5 (bonus)	EfficientNet-B0	1.142.202	features[-2:]=1e-4; classifier=1e-3	6 (11)	146,9	0,9764	0,0048	0,9664

Gambar 1. Kurva training loss vs validation loss untuk B1, B2, dan B3.



C2. Pembahasan Analisis Komparatif

C2.1 Disparitas performa B1 (from scratch) dengan B2 dan B3 (transfer learning)

Disparitas performa B1 dibanding B2 dan B3 sangat kontras. Pada tabel, B1 (*from scratch*) hanya mencetak Test Macro F1 0,6055 dengan *gap train-val* lebar sebesar 0,2023. Hal ini tervalidasi secara visual pada Gambar 1, di mana kurva *val loss* B1 sangat fluktuatif dan melompat-lompat. Sebaliknya, B2 dan B3 (*transfer learning*) unggul drastis dengan Test Macro F1 0,9667 dan 0,9530. Pada Gambar 1, *val loss* B2 stabil dan merapat ke *train loss*, sedangkan *val loss* B3 sudah rendah sejak epoch pertama dan relatif datar, dengan *train loss* yang turun jauh di bawahnya.

Sesuai konsep Slide 15, B1 harus melatih 11.181.642 parameter dari inisialisasi acak pada data yang kecil, sehingga rentan *overfitting* (*gap* 0,2023) dan membutuhkan waktu pelatihan terlama (447,9 detik). Fluktuasi *val loss* B1 kemungkinan dipengaruhi data latih yang kecil, inisialisasi acak, dan statistik *mini-batch* pada *Batch Normalization* yang kurang stabil (Slide 6-8). Perlu dicatat, B1 tidak pernah memicu *early stopping* (30 epoch penuh), sehingga mungkin belum benar-benar konvergen. Sebaliknya, B2 dan B3 mewarisi representasi fitur pra-latih yang sudah matang (Slide 14-15), sehingga hanya melatih sebagian kecil parameter (5.130 pada B2 dan 8.398.858 pada B3) dan menghasilkan akurasi yang stabil.

C2.2 Trade-off performa vs stabilitas: feature extraction vs fine-tuning

Perbandingan B2 (*feature extraction*) dan B3 (*fine-tuning*) menunjukkan *trade-off* antara kapasitas adaptasi model dan stabilitasnya. Berdasarkan tabel, B2 hanya memperbarui 5.130 parameter dan mencetak Test Macro F1 0,9667, sedikit di atas B3 (0,9530). Namun selisih tersebut setara sekitar 4 citra pada *test set*, sehingga keduanya dapat dianggap setara; B3 bahkan memiliki Val acc yang sedikit lebih tinggi (0,9630 berbanding 0,9562). Pada Gambar 1, kurva *val loss* B2 terlihat mulus dan stabil, sejalan dengan Slide 16 bahwa membekukan seluruh lapisan *backbone* melindungi fitur dasar dari kerusakan (*destructive updates*), sehingga aman untuk volume data latih yang terbatas.

Sebaliknya, B3 membuka *layer4* sehingga jumlah parameter yang diperbarui naik menjadi 8.398.858. Waktu pelatihannya lebih singkat (121,7 detik berbanding 375,7 detik pada B2), tetapi ini terutama karena konvergensi yang lebih cepat (9 epoch berbanding 27), bukan karena komputasi per epoch yang lebih ringan (waktu per epoch keduanya hampir sama). Dari sisi stabilitas, Gambar 1 menunjukkan *val loss* B3 cenderung naik setelah epoch 4 (0,130 menjadi 0,218 pada epoch 8) sementara *train loss* terus turun, tanda awal *overfitting* akibat banyaknya *trainable parameters* pada data yang terbatas. Pada eksperimen ini tidak ada bukti langsung *catastrophic forgetting* (Slide 28), terlebih *learning rate* B3 dibuat rendah (1e-4 untuk *layer4*). Dengan demikian, pada data sebesar ini *fine-tuning* tidak memberi keunggulan yang jelas dibanding *feature extraction*.

C2.3 Peran augmentasi dalam meredam overfitting (B4)

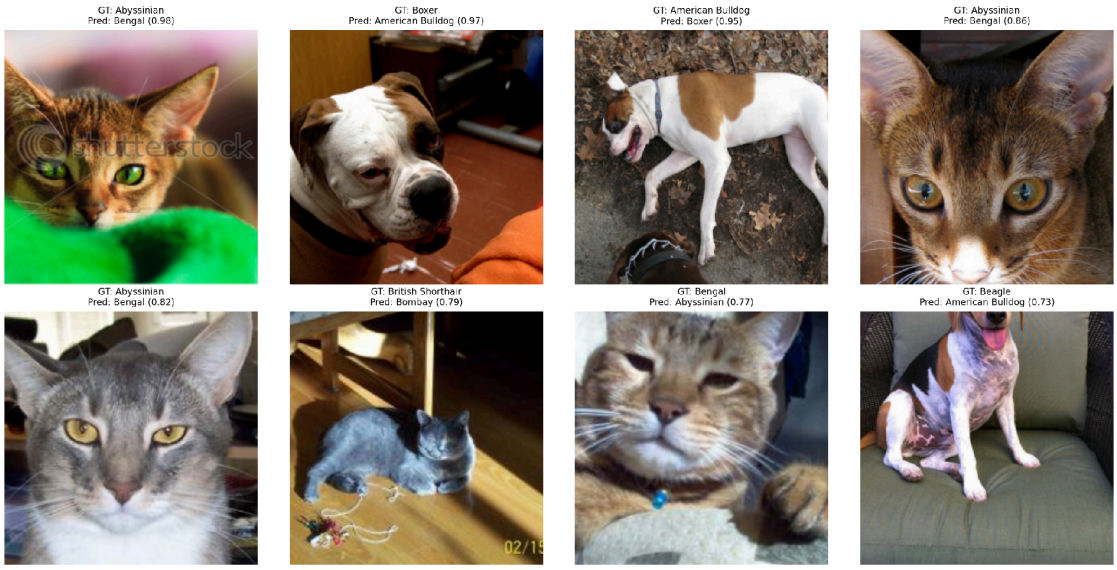
Perbandingan B4 (tanpa augmentasi) dan B3 (dengan augmentasi) memperlihatkan bahwa augmentasi menyempitkan celah (*gap*) akurasi *train-val*: 0,0303 pada B4 dibandingkan 0,0197 pada B3. Namun, akurasi B4 tidak lebih buruk: Val acc 0,9697 berbanding 0,9630, *val loss* 0,1147 berbanding 0,1295, dan Test Macro F1 0,9563 berbanding 0,9530.

Melebarnya *gap* pada B4 (akurasi latih 1,0) menunjukkan indikasi awal *overfitting* karena model menghafal sampel latih, sejalan dengan Slide 20 bahwa augmentasi mensimulasikan data latih tambahan

untuk meningkatkan generalisasi pada dataset kecil. Akan tetapi, selisih Val acc (0,0067) hanya setara sekitar 2 citra validasi, dan *gap* B3 juga menyempit sebagian karena akurasi latihnya dihitung pada citra beraugmentasi yang lebih sulit. Jadi, pada eksperimen ini augmentasi menekan *gap* tetapi tidak meningkatkan akurasi *validation* maupun *test*. Kemungkinannya, representasi pra-latih ImageNet sudah cukup kuat untuk domain ras kucing dan anjing sehingga manfaat tambahan augmentasi kecil (Slide 15).

C3. Failure Analysis

Model terbaik yang dianalisis: B3 (fine-tuning layer4 + fc), dipilih karena val acc tertinggi di antara kondisi ResNet-18 beraugmentasi (B1, B2, B3)



No	File	Ground truth	Prediksi	Confidence	Hipotesis penyebab kesalahan
1	Abyssinian_101.jpg	Abyssinian	Bengal	0,978	Kucing tertutup *watermark* "shutterstock" di wajah dan kain hijau besar yang menutupi area badannya, sehingga menghilangkan fitur tubuh secara utuh. Hilangnya corak badan ini kemungkinan merupakan fitur yang menyesatkan model secara meyakinkan dengan tingkat keyakinan yang sangat tinggi (0,978).
2	boxer_2.jpg	Boxer	American Bulldog	0,970	Pengambilan gambar *close-up* menonjolkan fitur wajah bermoncong pendek dan warna putih-cokelat yang sangat mirip dengan wajah American Bulldog. Karena proporsi tubuh yang menjadi pembeda utama kedua ras tidak terlihat di dalam *frame*, model

No	File	Ground truth	Prediksi	Confidence	Hipotesis penyebab kesalahan
					kemungkinan salah dengan keyakinan tinggi (0,970).
3	american_bulldog_164.jpg	American Bulldog	Boxer	0,955	Pose anjing yang berbaring menyamping secara *top-down* di atas latar dedaunan kering merusak siluet asli tubuhnya. Bentuk tubuh American Bulldog menjadi tersamarkan dan warna putih-cokelatnya tumpang tindih dengan Boxer, sehingga model kemungkinan salah dengan keyakinan tinggi (0,955).
4	Abyssinian_90.jpg	Abyssinian	Bengal	0,861	Gambar *extreme close-up* pada wajah memotong seluruh bagian tubuh kucing, sehingga corak bulu badannya yang khas tidak tampak sama sekali. Fokus pada garis-garis mata ini kemungkinan cukup meyakinkan model (0,861) untuk memprediksinya sebagai Bengal.
5	Abyssinian_221.jpg	Abyssinian	Bengal	0,824	Bulu kucing tampak keabu-abuan dengan nuansa kebiruan, berbeda dari warna cokelat kemerahan yang umum pada Abyssinian. Hal ini kemungkinan disebabkan pencahayaan atau karena kucing ini memang berwarna tidak khas, sehingga model kurang yakin (0,824) dan menebak Bengal.
6	British_Shorthair_230.jpg	British Shorthair	Bombay	0,792	Kucing tampak kecil di *frame* dan sebagian tubuhnya terkena bayangan kuat, sehingga warna abu-abunya tampak lebih gelap dan menyerupai Bombay (ras berbulu hitam). Area lantai dan bayangan yang luas serta teks tanggal di pojok gambar juga kemungkinan mengalihkan fokus model, sehingga keyakinannya relatif lebih rendah (0,792).
7	Bengal_143.jpg	Bengal	Abyssinian	0,768	Gambar tampak buram dan hanya menampilkan area wajah, sehingga corak roset (totol) khas Bengal pada tubuh tidak terlihat. Hilangnya fitur pembeda ini

No	File	Ground truth	Prediksi	Confidence	Hipotesis penyebab kesalahan
					kemungkinan membuat model sulit membedakannya dari Abyssinian, terlihat dari keyakinannya yang relatif lebih rendah (0,768).
8	beagle_64.jpg	Beagle	American Bulldog	0,728	Anjing duduk di kursi sehingga area punggung tertutup dan corak pelana khas Beagle tidak bisa diamati. Dada dan perut putih yang terekspos kemungkinan membuat model memprediksi American Bulldog dengan keyakinan relatif lebih rendah (0,728).

Catatan: delapan sampel ini diurutkan dari confidence tertinggi, bukan sampel acak. Dari delapan sampel yang ditampilkan, seluruh kesalahan terjadi antar ras dalam spesies yang sama (kucing ke kucing, anjing ke anjing), tanpa kesalahan lintas spesies. Pasangan yang berulang adalah Abyssinian yang diprediksi Bengal (3 kali) serta Boxer dan American Bulldog yang saling tertukar (2 kali), sehingga kesalahan paling sering terjadi pada ras yang mirip secara visual dan diperparah oleh kondisi gambar (close-up, pencahayaan, oklusi, kualitas gambar).

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Rekomendasi untuk tim rekayasa industri

Untuk skenario peluncuran model dengan data latih terbatas, rekomendasi saya adalah memulai dari strategi *Feature Extraction* (B2). Berdasarkan Tabel C1, B2 hanya melatih 5.130 parameter, namun mencapai Test Macro F1 0,9667 dengan *gap train-val* 0,0200, jauh di atas B1 (*from scratch*) yang hanya 0,6055 dengan *gap* 0,2023. Selisih B2 terhadap B3 (0,9530) dan B4 (0,9563) setara sekitar 4 citra pada *test set* sehingga tidak bisa dianggap keunggulan nyata (lihat C2.2). Alasan memilih B2 adalah kesederhanaan dan risiko yang lebih kecil: hanya *classifier head* yang dilatih sehingga tidak ada risiko merusak fitur *pretrained* (Slide 16), bukan karena B2 terbukti paling akurat. Rekomendasi ini berlaku pada kondisi data latih sedikit dan domain objek mirip dengan ImageNet (Slide 15), seperti ras kucing dan anjing pada eksperimen ini. Perlu dicatat, B2 tidak lebih cepat dari B3 pada Tabel C1 (375,7 detik berbanding 121,7 detik) karena B2 menjalankan lebih banyak epoch (27 berbanding 9), sehingga penghematan komputasi tidak bisa diklaim dari data ini.

Rekomendasi ini perlu ditinjau ulang menuju *Fine-Tuning* sebagian (seperti B3) apabila tim memiliki data latih baru yang lebih banyak dan teranotasi baik, atau domain datanya berbeda jauh dari ImageNet, misalnya citra medis atau *satellite imagery* (Slide 15-16). Kondisi ini bersandar pada konsep materi dan belum diuji pada eksperimen ini, karena pada data hewan peliharaan fine-tuning (B3) tidak memberi keunggulan yang jelas dibanding B2. Jika *fine-tuning* dipakai, *learning rate* backbone perlu dibuat rendah (Slide 28-29).

Batasan studi

- **Pengujian dilakukan hanya menggunakan satu *seed* tunggal (42)**, sehingga variasi metrik bisa dipengaruhi oleh kebetulan inisialisasi dan pembagian data, dan tidak ada interval kepercayaan.
- **Dataset yang digunakan hanya berskala kecil (10 dari 37 kelas Oxford-IIIT Pet, domainnya hewan peliharaan yang mirip ImageNet)**, sehingga tidak sepenuhnya mewakili kompleksitas variasi kelas di skenario industri sesungguhnya.
- **Anggaran komputasi dibatasi** (maksimum 30 epoch, *early stopping* dengan *patience* 5 pada *val loss*, *hyperparameter* tidak di-*tuning*). B1 tidak pernah memicu *early stopping* sehingga mungkin belum konvergen, dan waktu pelatihan pada Tabel C1 dipengaruhi jumlah epoch serta waktu pemuatan data, bukan hanya biaya komputasi per strategi.
- **Ukuran *test set* sangat kecil (sekitar 298 citra)**, sehingga satu citra setara sekitar 0,34 poin akurasi. Selisih Macro F1 antar B2, B3, B4, dan B5 (sekitar 0,01) belum tentu bermakna.
- **Cakupan variasi eksperimen sempit**: *hyperparameter* (*learning rate*, optimisator) tidak divariasikan, B4 hanya menguji augmentasi pada konfigurasi B3, dan B5 (EfficientNet-B0) hanya satu konfigurasi, sehingga konfigurasi yang tampak kurang unggul mungkin belum mencapai potensi puncaknya. Analisis kegagalan (C3) juga hanya mencakup 8 kesalahan dengan *confidence* tertinggi, bukan seluruh kesalahan.

Referensi

1. Materi kuliah Sesi 05: Advanced CNNs and Transfer Learning (slide).

Lampiran: Pernyataan Penggunaan AI (AI Disclosure Statement)

Poin	Isian
Nama model/alat AI yang digunakan	Claude (Anthropic), model Claude Sonnet 5.5, Claude Code / claude.ai.
Ruang lingkup bantuan AI pada tugas ini	(1) Menyusun kerangka kode notebook (pipeline data, pelatihan B1-B5, failure analysis, Grad-CAM) beserta debugging dan requirements.txt/README. (2) Klarifikasi konsep (Batch Normalization, residual connection, transfer learning, augmentation, catastrophic forgetting) dan penjelasan cara membaca hasil. (3) Peninjauan draf tulisan saya pada Bagian A, C2, C3, C4, serta perbaikan akurasi kata dan angka pada beberapa kalimat (misalnya penjelasan gradien pada A2, rujukan nomor slide, dan penyesuaian klaim agar sesuai data). Draf awal analisis, hipotesis, dan kesimpulan ditulis oleh saya sendiri, AI tidak menghasilkan angka eksperimen.
Cara saya memverifikasi kebenaran keluaran AI secara mandiri	Notebook dijalankan sendiri di Google Colab dan seluruh angka pada laporan diambil dari file log (metrics_summary.csv/json dan history_*.csv) yang dihasilkan notebook, lalu dicocokkan ulang dengan Tabel C1. Konsep dicek terhadap slide materi Sesi 05 (nomor slide dicantumkan pada tiap klaim), dan hipotesis failure analysis dicek dengan melihat langsung gambar pada sampel. Serta membaca keseluruhan isi laporan agar tidak ada data yang tidak sesuai.